Generazione e valutazione di grafi mediante stima e diffusione di graphon

TODO: Nome Cognome

17 luglio 2026

Indice

1 Introduzione **2**
1.1 Obiettivi 3
1.2 Fondamenti bibliografici 3

2 Contesto teorico **5**
2.1 Graphon e generazione di grafi 5
2.2 Diffusione in spazi discreti 6
2.3 Generazione di grafi con DiGress 8
2.4 Valutazione tramite MMD 8

3 Pipeline proposta **10**
3.1 Architettura generale 10
3.2 Campionamento dai graphon generati 11
3.3 Protocollo di confronto 12

4 Primi risultati **13**

5 Conclusioni provvisorie **14**

Capitolo 1

Introduzione

La generazione di grafi e' un problema centrale nello studio di dati relazionali: molte applicazioni, dalle reti sociali ai sistemi biologici, richiedono modelli in grado di produrre nuove istanze che preservino proprieta' strutturali osservate in un insieme di esempi. A differenza dei dati vettoriali o delle immagini, i grafi combinano una struttura combinatoria discreta con vincoli di invarianza rispetto alla permutazione dei nodi. Questa natura rende non banale sia la definizione di modelli generativi efficaci, sia la loro valutazione quantitativa.

Il presente lavoro considera una pipeline sperimentale per la generazione di grafi basata su graphon. Un graphon puo' essere interpretato come una funzione simmetrica $W : [0, 1]^2 \to [0, 1]$, dalla quale e' possibile campionare grafi scegliendo variabili latenti associate ai nodi e generando archi indipendenti con probabilita' data dal valore di W. In questa prospettiva, il graphon fornisce una rappresentazione continua e non parametrica della struttura probabilistica di una famiglia di grafi.

La pipeline studiata in questa tesi, indicata nel repository come OGAD, combina tre blocchi principali. In primo luogo, a partire da grafi osservati, SIGL stima graphon mediante rappresentazioni neurali implicite e reti neurali su grafi [2]. In secondo luogo, i graphon stimati sono usati come dati di training per un modello generativo discreto: nella configurazione corrente sono considerate sia una variante D3PM, basata su modelli di diffusione in spazi di stati discreti [1, 11], sia una variante DiGress adattata alla generazione di graphon discretizzati [14]. Infine, i graphon generati vengono convertiti in grafi e valutati con metriche MMD su descrittori strutturali, seguendo le indicazioni metodologiche di GGME [10].

1.1 Obiettivi

L'obiettivo del lavoro e' analizzare se una rappresentazione intermedia basata su graphon possa migliorare o rendere piu' controllabile la generazione di grafi. In particolare, la pipeline non genera direttamente matrici di adiacenza, ma apprende una distribuzione sui graphon stimati dai dati. I grafi finali sono poi ottenuti campionando da tali graphon e scegliendo il numero di nodi dalla distribuzione empirica del test set.

Gli obiettivi sperimentali possono essere riassunti come segue:

- stimare graphon rappresentativi del training set mediante SIGL;
- addestrare un generatore discreto sui graphon stimati;
- confrontare il generatore OGAD con baseline disponibili, tra cui DiGress e i risultati indicati come «Paper» nella pipeline di valutazione;
- valutare i grafi generati tramite MMD su distribuzione dei gradi, coefficiente di clustering e spettro del laplaciano normalizzato.

1.2 Fondamenti bibliografici

Il lavoro si colloca all'intersezione tra teoria dei graphon, stima statistica di reti e modelli generativi profondi per grafi. Dal punto di vista teorico, i graphon nascono come oggetti limite per sequenze dense di grafi [9, 8]; la connessione con i modelli di grafo scambiabili e con la rappresentazione di Aldous–Hoover e' discussa in modo esplicito da Diaconis e Janson [5]. Questa base giustifica l'uso del graphon come rappresentazione probabilistica non parametrica della struttura di una famiglia di grafi.

Sul piano statistico, la stima di graphon e' stata studiata sia come problema minimax sia come problema computazionale. Gao, Lu e Zhou stabiliscono tassi ottimali per la stima di graphon e mettono in evidenza il legame con modelli a blocchi stocastici e regressione non parametrica [6]. Borgs e Chayes presentano invece una prospettiva piu' ampia sull'uso dei graphon per modellare, stimare e progettare algoritmi su reti massive [3]. SIGL si inserisce in questa linea introducendo una stima continua e scalabile basata su implicit neural representations e GNN [2].

Per quanto riguarda la generazione di grafi, GraphRNN rappresenta un riferimento classico per i modelli autoregressivi e ha contribuito a rendere comune la valutazione tramite MMD su descrittori strutturali [15]. Altri lavori, come GraphVAE e MolGAN, mostrano approcci alternativi basati rispettivamente su autoencoder variazionali e modelli avversari [12, 4]. La componente

diffusiva della tesi si collega invece ai diffusion probabilistic models [7], alla formulazione score-based tramite equazioni differenziali stocastiche [13], e alla loro estensione a spazi discreti tramite D3PM [1].

Capitolo 2

Contesto teorico

2.1 Graphon e generazione di grafi

Un graphon e' una funzione misurabile, simmetrica e limitata

$$W : [0,1]^2 \to [0,1], \qquad W(u,v) = W(v,u).$$

Dato un intero $M \in \mathbb{N}$, il graphon induce una distribuzione su grafi semplici non orientati con M nodi. Il modello generativo associato puo' essere scritto come

$$\begin{aligned} u_1, \dots, u_M &\overset{\text{i.i.d.}}{\sim} \text{Uniform}(0,1), \\ A_{ij} \mid u_i, u_j, W &\sim \text{Bernoulli}(W(u_i, u_j)), \qquad 1 \le i < j \le M, \end{aligned}$$

con $A_{ji} = A_{ij}$ e $A_{ii} = 0$. In altre parole, condizionatamente alle variabili latenti dei nodi, gli archi sono indipendenti e la probabilita' di un arco dipende solo dal valore del graphon nella coppia di coordinate latenti:

$$\mathbb{P}(A_{ij} = 1 \mid u_i, u_j, W) = W(u_i, u_j).$$

Nel caso implementativo, W non e' rappresentato come funzione continua ma come matrice $R \times R$, con $R = 128$. Indicando con $\widehat{W} \in [0,1]^{R \times R}$ tale discretizzazione, il campionamento viene approssimato scegliendo indici

$$z_i = \lfloor R u_i \rfloor, \qquad z_i \in \{0, \dots, R-1\},$$

e ponendo

$$A_{ij} \mid z_i, z_j, \widehat{W} \sim \text{Bernoulli}(\widehat{W}_{z_i, z_j}).$$

Prima del campionamento, la pipeline applica una proiezione $\Pi : \mathbb{R}^{R \times R} \to [0,1]^{R \times R}$ che impone vincoli strutturali:

$$\Pi(X)_{ij} = \begin{cases} 0, & i = j, \\ \min\{1, \max\{0, (X_{ij} + X_{ji})/2\}\}, & i \neq j. \end{cases}$$

Questa operazione rende espliciti i vincoli di grafo semplice non orientato: probabilita' valide, simmetria e assenza di self-loop.

Questa rappresentazione e' utile perche' separa due problemi: la stima di una struttura probabilistica continua a partire da grafi osservati e la generazione di nuove istanze discrete a partire da tale struttura. Nel repository, SIGL e' usato per il primo passaggio: dato un insieme di grafi, produce graphon su griglia che vengono salvati come immagini o tensori e poi usati dal modello generativo. Poiche' la rappresentazione tramite graphon e' definita a meno di trasformazioni misura-preservanti dello spazio latente, la stima richiede anche un problema di allineamento o ordinamento dei nodi. Questo aspetto e' rilevante nella pipeline OGAD, perche' la qualita' del generatore successivo dipende dalla coerenza dei graphon stimati nella fase SIGL.

Formalmente, due graphon W e W' rappresentano lo stesso modello limite se esiste una trasformazione misura-preservante $\varphi : [0,1] \to [0,1]$ tale che

$$W'(u,v) = W(\varphi(u), \varphi(v)) \quad \text{quasi ovunque.}$$

Ne segue che il problema di apprendere una distribuzione sui graphon stimati non riguarda solo la qualita' punto per punto della matrice $\widehat{W}$, ma anche la stabilita' della rappresentazione scelta per l'ordinamento latente.

2.2 Diffusione in spazi discreti

I modelli di diffusione apprendono a invertire un processo di corruzione progressiva dei dati. Nei modelli continui, la corruzione e' spesso descritta come aggiunta di rumore gaussiano; nei contesti discreti, invece, e' necessario definire transizioni tra stati discreti. D3PM formalizza questa idea introducendo processi di diffusione per variabili categoriali e mostrando come modellare la dinamica inversa in spazi di stati discreti [1]. La scelta di un modello discreto e' coerente con la natura dei grafi e con la discretizzazione dei valori del graphon: invece di perturbare direttamente valori continui, si apprende una dinamica su classi di probabilita'.

Sia $x_0 \in \{1, \dots, K\}^d$ una rappresentazione categoriale di un graphon discretizzato, dove K e' il numero di bin di probabilita' e d e' il numero di celle modellate. Un processo diffusivo discreto definisce una catena di Markov in avanti

$$q(x_{1:T} \mid x_0) = \prod_{t=1}^{T} q(x_t \mid x_{t-1}),$$

dove ogni transizione e' descritta da una matrice stocastica $Q_t \in [0,1]^{K \times K}$:

$$q(x_t \mid x_{t-1}) = \mathrm{Cat}(x_t; x_{t-1} Q_t)\,.$$

Il modello generativo apprende invece una catena inversa parametrica

$$p_\theta(x_{0:T}) = p(x_T) \prod_{t=1}^{T} p_\theta(x_{t-1} \mid x_t),$$

con l'obiettivo di approssimare la distribuzione dei graphon osservati dopo la fase SIGL. In forma variazionale, l'addestramento minimizza una decomposizione del negative log-likelihood:

$$-\log p_\theta(x_0) \leq \mathbb{E}_{q(x_{1:T}|x_0)} \Bigg[-\log p_\theta(x_0 \mid x_1) + \sum_{t=2}^{T} D_{\mathrm{KL}}\big(q(x_{t-1} \mid x_t, x_0) \,\|\, p_\theta(x_{t-1} \mid x_t)\big) \Bigg] + C,$$

dove C non dipende da θ. Questa scrittura mette in evidenza il ruolo del modello neurale: stimare, per ogni livello di rumore, la distribuzione del passo inverso.

Nel contesto di questa tesi, i graphon sono rappresentati su una griglia 128×128 e i valori di probabilita' possono essere discretizzati in un numero finito di classi. Cio' consente di trattare la generazione del graphon come un problema discreto, compatibile sia con l'implementazione D3PM presente nel repository, sia con l'adattamento di DiGress ai graphon. Nella configurazione DiGress, ogni cella fuori diagonale del graphon e' trattata come una classe categoriale; l'output e' poi ricondotto a un tensore simmetrico in $[0, 1]$ con diagonale nulla.

In termini di pipeline, si parte da un insieme di graphon stimati

$$\widehat{\mathcal{W}} = \{\widehat{W}_1, \ldots, \widehat{W}_n\}, \qquad \widehat{W}_i \in [0,1]^{R \times R},$$

li si quantizza tramite una funzione

$$b : [0,1] \to \{1, \ldots, K\},$$

e si addestra il modello sulla collezione

$$x_i = b(\widehat{W}_i).$$

La fase di generazione produce campioni $\widetilde{x}$, che vengono dequantizzati in $\widetilde{W}$ e successivamente usati come kernel di campionamento per ottenere grafi discreti.

2.3 Generazione di grafi con DiGress

DiGress e' un modello di diffusione discreta progettato per la generazione di grafi [14]. Il suo interesse per questo lavoro deriva dal fatto che opera naturalmente su strutture discrete e puo' essere usato come baseline per la generazione diretta di grafi. Nel repository OGAD e' presente anche una modalita' alternativa in cui DiGress viene usato non per generare direttamente grafi, ma per generare graphon discretizzati. Tale variante legge i graphon prodotti da SIGL, usa un numero configurabile di bin di probabilita' e scrive tensori compatibili con lo stadio GGME.

2.4 Valutazione tramite MMD

La valutazione dei modelli generativi per grafi e' particolarmente delicata: metriche apparentemente naturali possono risultare instabili o poco informative se non vengono associate a descrittori strutturali e kernel appropriati. GGME affronta questo problema studiando l'uso della Maximum Mean Discrepancy (MMD) per confrontare distribuzioni di grafi [10].

Siano $\mathcal{P}$ e $\mathcal{Q}$ due distribuzioni su grafi e sia $\phi : \mathcal{G} \to \mathbb{R}^m$ un descrittore strutturale, ad esempio la distribuzione dei gradi o lo spettro del laplaciano normalizzato. Data una funzione kernel positiva definita $k : \mathbb{R}^m \times \mathbb{R}^m \to \mathbb{R}$, la MMD tra le distribuzioni indotte dai descrittori e' definita come

$$\begin{aligned}\mathrm{MMD}_k^2(\mathcal{P}, \mathcal{Q}) = \mathbb{E}_{G,G' \sim \mathcal{P}} k(\phi(G), \phi(G')) \\ + \mathbb{E}_{H,H' \sim \mathcal{Q}} k(\phi(H), \phi(H')) \\ - 2\mathbb{E}_{G \sim \mathcal{P}, H \sim \mathcal{Q}} k(\phi(G), \phi(H)).\end{aligned}$$

Dato un campione osservato $\{G_i\}_{i=1}^n$ e un campione generato $\{H_j\}_{j=1}^m$, la stima empirica usata nella valutazione ha la forma

$$\begin{aligned}\widehat{\mathrm{MMD}}_k^2 = \frac{1}{n^2} \sum_{i=1}^{n} \sum_{i'=1}^{n} k(\phi(G_i), \phi(G_{i'})) \\ + \frac{1}{m^2} \sum_{j=1}^{m} \sum_{j'=1}^{m} k(\phi(H_j), \phi(H_{j'})) \\ - \frac{2}{nm} \sum_{i=1}^{n} \sum_{j=1}^{m} k(\phi(G_i), \phi(H_j)).\end{aligned}$$

Nella pipeline sono considerati kernel lineari e gaussiani; nel secondo caso, per descrittori $a, b \in \mathbb{R}^m$,

$$k_\sigma(a, b) = \exp\left(-\frac{\|a - b\|_2^2}{2\sigma^2}\right).$$

Nella pipeline OGAD, la valutazione segue tre passaggi. Per ciascun descrittore, vengono generate versioni perturbate del test set e viene selezionata la combinazione di kernel e iperparametri che massimizza la correlazione con il livello di perturbazione. Successivamente, la stessa configurazione viene usata per misurare la distanza tra il test set e le distribuzioni prodotte dai modelli. I descrittori attualmente usati sono:

- distribuzione dei gradi;
- coefficiente di clustering;
- spettro del laplaciano normalizzato.

Capitolo 3

Pipeline proposta

3.1 Architettura generale

La pipeline implementata nel repository segue la sequenza:

SIGL $\rightarrow$ D3PM/DiGress su graphon $\rightarrow$ campionamento di grafi $\rightarrow$ GGME.

Lo script principale `scripts/run_ogad_experiment.sh` orchestra le tre fasi in container separati. La prima fase prepara i dati e stima i graphon; la seconda addestra o esegue il generatore di graphon; la terza converte i graphon generati in grafi e calcola le metriche di valutazione.

Indicando con

$$\mathcal{D}_{\text{train}} = \{G_1, \dots, G_N\}$$

il training set di grafi, la prima fase produce una collezione

$$\widehat{\mathcal{W}} = S_\psi(\mathcal{D}_{\text{train}}) = \{\widehat{W}_1, \dots, \widehat{W}_L\},$$

dove S_ψ rappresenta lo stimatore SIGL. Il generatore di graphon apprende quindi una distribuzione $p_\theta(W)$ approssimata tramite campioni $\widetilde{W}_1, \dots, \widetilde{W}_S \sim p_\theta$. La fase finale induce una distribuzione su grafi

$$\widetilde{G} \sim \mathbb{P}(\,\cdot \mid \widetilde{W}, M),$$

dove M e' campionato dalla distribuzione empirica delle dimensioni dei grafi di test. Il confronto sperimentale puo' quindi essere formulato come minimizzare, implicitamente, una distanza tra la distribuzione reale dei grafi e quella generata:

$$\mathbb{P}_{\mathcal{G}}^{\text{test}} \quad \text{vs.} \quad \mathbb{P}_{\mathcal{G},\theta,\psi}^{\text{OGAD}}.$$

La configurazione sperimentale e' descritta tramite file JSON. Nella configurazione raffinata per D3PM, SIGL usa 100 epoche, learning rate 0.06, risoluzione 128, 50 cluster e bootstrap replicate $13, 14, 15, 16$. La parte D3PM esplora batch size 32, dimensione latente 512, learning rate tra $2 \cdot 10^{-5}$ e $5 \cdot 10^{-5}$, numero di classi in $\{10, 12, 14\}$ e coefficienti di loss ibrida in $\{0.006, 0.01, 0.015\}$. L'addestramento prevede split di validazione pari a 0.2, patience 25 e massimo 300 epoche.

La configurazione DiGress su graphon usa la stessa fase SIGL, ma sostituisce il generatore D3PM con una diffusione categoriale DiGress. In questa modalita' il modello usa 10 bin di probabilita', risoluzione 128, batch size 2, accumulo gradiente pari a 16, 200 epoche massime e produce 16 graphon finali. Entrambe le modalita' producono tensori compatibili con GGME, con forma $[N, 1, 128, 128]$.

3.2 Campionamento dai graphon generati

Dopo la generazione, ogni graphon viene sanificato imponendo simmetria, valori nel range $[0, 1]$ e diagonale nulla. Per produrre un insieme fissato di grafi, la pipeline seleziona ciclicamente i graphon disponibili e campiona il numero di nodi dalla distribuzione empirica dei grafi nel test set. Questo accorgimento riduce il rischio che differenze nelle metriche siano dovute soltanto a una distribuzione diversa delle dimensioni dei grafi.

Sia

$$\mathcal{D}_{\text{test}} = \{G_1^{\text{test}}, \dots, G_n^{\text{test}}\}$$

il test set e siano

$$m_i = |V(G_i^{\text{test}})|$$

le dimensioni dei grafi osservati. La distribuzione empirica delle dimensioni e'

$$\widehat{\mu}_M = \frac{1}{n} \sum_{i=1}^{n} \delta_{m_i},$$

dove δ_{m_i} indica una massa di Dirac in m_i. Per generare il campione r-esimo, la pipeline sceglie un graphon generato

$$\widetilde{W}^{(r)} = \widetilde{W}_{1+((r-1) \bmod S)},$$

campiona $M_r \sim \widehat{\mu}_M$ e poi genera

$$\widetilde{G}_r \sim \mathbb{P}(\,\cdot \mid \Pi(\widetilde{W}^{(r)}), M_r).$$

Il dataset generato usato in valutazione e' quindi

$$\widetilde{\mathcal{D}} = \{\widetilde{G}_1, \ldots, \widetilde{G}_B\},$$

dove B e' il numero di grafi richiesto dalla configurazione sperimentale.

3.3 Protocollo di confronto

Lo stadio GGME confronta tre insiemi di grafi con il test set:

- i grafi generati da DiGress, quando disponibili;
- i grafi generati dalla pipeline OGAD a partire dai graphon;
- i grafi indicati come «Paper», usati come riferimento esterno nella configurazione sperimentale.

Per ciascun descrittore viene riportata la MMD rispetto al test set. Valori piu' bassi indicano una maggiore somiglianza secondo il descrittore e il kernel selezionati.

L'uso di piu' descrittori e' importante perche' nessuna singola statistica riassume completamente una distribuzione di grafi. La distribuzione dei gradi cattura proprieta' locali di connettivita', il coefficiente di clustering misura tendenze triadiche, mentre lo spettro del laplaciano normalizzato fornisce una descrizione piu' globale della struttura. Questa scelta rende il confronto piu' robusto, ma non elimina la dipendenza della MMD dal kernel, dai parametri del kernel e dalla specifica funzione descrittiva; proprio per questo GGME propone di selezionare tali elementi rispetto a perturbazioni controllate del test set.

Capitolo 4

Primi risultati

I risultati preliminari presenti nel README mostrano che il comportamento varia sensibilmente in funzione del descrittore. Nel test con 200 cluster, per la distribuzione dei gradi la MMD riportata e' 0.0125 per DiGress, 0.6301 per OGAD e 0.0034 per il riferimento Paper. Per il coefficiente di clustering, i valori sono rispettivamente 99.7936, 2458.3862 e 16.0080. Per lo spettro del laplaciano normalizzato, i valori sono 1.8530, 44.1202 e 0.5686.

Questi risultati non sono ancora sufficienti per una conclusione definitiva, ma indicano due direzioni di analisi. La prima riguarda la qualita' dei graphon stimati e generati: errori anche piccoli nella struttura probabilistica possono amplificarsi durante il campionamento dei grafi. La seconda riguarda la scelta del generatore discreto e della discretizzazione dei valori del graphon: il numero di classi, il tipo di rumore e la risoluzione della griglia influenzano direttamente la capacita' del modello di rappresentare strutture locali come triangoli e clustering.

Capitolo 5

Conclusioni provvisorie

La pipeline OGAD propone una scomposizione modulare del problema di generazione di grafi: prima si stimano graphon dai dati osservati, poi si apprende una distribuzione sui graphon, infine si campionano grafi e li si valuta con metriche strutturali. Questa impostazione rende esplicita la rappresentazione intermedia appresa dal modello e permette di confrontare generatori discreti diversi nello stesso protocollo sperimentale.

Il prossimo passo consiste nel consolidare il protocollo sperimentale: generare la stessa quantita' di grafi per OGAD e DiGress, estendere la valutazione a tutte le funzioni descrittive disponibili, analizzare l'effetto del rumore introdotto sui graphon e ripetere gli esperimenti su piu' epoche e configurazioni di discretizzazione.

Bibliografia

[1] Jacob Austin, Daniel D. Johnson, Jonathan Ho, Daniel Tarlow, and Rianne van den Berg. Structured denoising diffusion models in discrete state-spaces. *Advances in Neural Information Processing Systems*, 34:17981–17993, 2021.

[2] Ali Azizpour, Nicolas Zilberstein, and Santiago Segarra. Scalable implicit graphon learning. In *International Conference on Artificial Intelligence and Statistics*, pages 3952–3960, 2025.

[3] Christian Borgs and Jennifer Chayes. Graphons: A nonparametric method to model, estimate, and design algorithms for massive networks. Microsoft Research preprint, 2017.

[4] Nicola De Cao and Thomas Kipf. Molgan: An implicit generative model for small molecular graphs, 2018.

[5] Persi Diaconis and Svante Janson. Graph limits and exchangeable random graphs. *Rendiconti di Matematica e delle sue Applicazioni*, 28(1):33–61, 2008.

[6] Chao Gao, Yu Lu, and Harrison H. Zhou. Rate-optimal graphon estimation. *The Annals of Statistics*, 43(6):2624–2652, 2015.

[7] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems*, volume 33, pages 6840–6851, 2020.

[8] Laszlo Lovasz. *Large Networks and Graph Limits*, volume 60 of *American Mathematical Society Colloquium Publications*. American Mathematical Society, 2012.

[9] Laszlo Lovasz and Balazs Szegedy. Limits of dense graph sequences. *Journal of Combinatorial Theory, Series B*, 96(6):933–957, 2006.

[10] Leslie O'Bray, Max Horn, Bastian Rieck, and Karsten Borgwardt. Evaluation metrics for graph generative models: Problems, pitfalls, and practical solutions. In *International Conference on Learning Representations*, 2022.

[11] Simo Ryu. Minimal implementation of a d3pm (structured denoising diffusion models in discrete state-spaces), in pytorch. `https://github.com/cloneofsimo/d3pm`, 2024. Repository used as implementation reference.

[12] Martin Simonovsky and Nikos Komodakis. Graphvae: Towards generation of small graphs using variational autoencoders. In *Artificial Neural Networks and Machine Learning – ICANN 2018*, pages 412–422. Springer, 2018.

[13] Yang Song, Jascha Sohl-Dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. In *International Conference on Learning Representations*, 2021.

[14] Clement Vignac, Igor Krawczuk, Antoine Siraudin, Bohan Wang, Volkan Cevher, and Pascal Frossard. Digress: Discrete denoising diffusion for graph generation. In *The Eleventh International Conference on Learning Representations*, 2023.

[15] Jiaxuan You, Rex Ying, Xiang Ren, William Hamilton, and Jure Leskovec. Graphrnn: Generating realistic graphs with deep auto-regressive models. In *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *Proceedings of Machine Learning Research*, pages 5708–5717. PMLR, 2018.